

CONCLUSIONES DEL ANÁLISIS DEL DATASET

Integrantes:

- Espínola, Carla
- Gambarte, Antonella Nerea
- Torres, Dimas Ignacio

Elegimos el dataset de [PlantVillage](#) para resolver un problema de clasificación que consistirá en entrenar un modelo para identificar una enfermedad específica en una especie de planta.

Carga del dataset y etiquetado

Al cargar el dataset notamos que se encuentra dividido en tres subcarpetas: color, grayscale y segmented. La primera contiene las imágenes en color, la segunda tiene las mismas imágenes pero en escala de grises y la última tiene las mismas imágenes pero sin el fondo.

Dentro de cada carpeta, las imágenes se encuentran ya etiquetadas de la siguiente manera:

<Planta>__<Enfermedad/healthy>

Donde:

- Planta: nombre de la planta.
- Enfermedad/healthy: nombre de la enfermedad. Si se trata de imágenes de plantas sanas, se etiqueta healthy.

Cantidad de imágenes y número de clases

Existen en total 162916 imágenes. Según el tipo, las cantidades son las siguientes:


Tipo	Cantidad
Color	54305
Grayscale	54305
Segmented	54306

No se detectaron archivos de imagen dañados o ilegibles.

En cuanto al número de clases, en cada carpeta existen 38 clases.

Distribución de clases

A continuación, se muestra la distribución de las categorías según las clases:



Se puede observar que hay un sesgo hacia las enfermedades con mayor relevancia económica como la infección de cítricos llamada Huanglongbing (HLB) o "Greening" la cual no tiene cura o el "Curl Virus" del tomate. Esta información es importante para evaluar cómo afecta este desbalance de clases en el entrenamiento del modelo.

Se deberá evaluar la necesidad de aplicar técnicas que permitan mitigar este sesgo como por ejemplo data augmentation sobre clases minoritarias o el uso de pesos por clase en el modelo a entrenar.

Tamaño de imágenes

Se realizó un análisis de los tamaños que presentan las imágenes. Estos fueron los tamaños encontrados:

Tipo	Ancho	Altura	Cantidad
Color	256	256	54305
Grayscale	256	256	54305
Segmented	256	256	54302
Segmented	324	512	1
Segmented	335	512	1
Segmented	466	512	1


Segmented	470	512	1
-----------	-----	-----	---

Como se observa, la totalidad de las imágenes a color y escala de grises son del mismo tamaño (256x256). Para las segmentadas, 54302 son del tamaño 256x256 y 4 solamente presentan tamaños más grandes. En caso de usar las imágenes segmentadas, será necesario un reescalamiento.

Duplicados

Se analizó si existían duplicados de imágenes. Para ello, se hizo el análisis calculando un hash MD5 para cada imagen. Al realizar este cálculo, lo que se toma son los datos binarios del archivo. Si las imágenes son exactamente iguales en su contenido (es decir todos sus píxeles, formato, tamaño, compresión, etc), entonces se genera el mismo hash.


Con este método se logró detectar 63 grupos de duplicados. Se muestran algunos ejemplo a continuación:



En total son 126 imágenes duplicadas, lo que representa un 0.08% de duplicados sobre el total. No es un número elevado, pero es algo a tener en cuenta al momento de realizar la limpieza del dataset.

Análisis de colores


Observamos que varias enfermedades parecen presentar como síntoma la clorosis, amarillamiento de la hoja. Es por ello, que se planteó un gráfico que compare la proporción entre amarillo y verde en cada clase.




En el gráfico vemos cómo el amarillo es característico de algunas enfermedades como "Grape_lead_blight". Esta información puede ser útil al entrenar el modelo, ya que indica que es importante utilizar las imágenes a color en lugar de las de escala de grises. La coloración que adquieren las plantas nos ayuda a identificar y diferenciar posibles enfermedades.

Como ejemplo, tomamos una muestra de "Grape" enferma y sana y observamos la distribución del color verde y amarillo en la imagen.


Imágen con etiqueta **Grape__Leaf_blight_(Isariopsis_Leaf_Spot)**:



Imágen con etiqueta **Grape__healthy**:










Además, también podemos agregar información de las hojas que tienen manchas usando la distribución de colores RGB.



Análisis de distribuciones globales de color

A continuación, se muestran gráficos que muestran la distribución de colores entre clases:






Analizando los gráficos generados para cultivos como tomate, papa, manzana y frutilla, se observa un patrón consistente: la clase "Sana" siempre presenta una barra de color verde notablemente más alta que las enfermedades. Esto confirma que la pérdida de verdor de la hoja es indicador de estrés en la planta, independientemente de la especie.

En cuanto a las enfermedades específicas, los gráficos muestran firmas de color distintivas que permiten diferenciarlas. Por ejemplo, el tizón en la papa dispara los niveles de marrón, indicando necrosis rápida, mientras que enfermedades virales en el tomate elevan el amarillo (clorosis) y en la frutilla aparecen picos de rojo debido a sus lesiones características. Esto valida que el dataset contiene información cromática suficiente para que un modelo pueda clasificar no solo "sano vs. enfermo", sino el tipo específico de patología.

Análisis de brillo y saturación

Existen algunas imágenes de la misma etiqueta que tienen más brillo que otras, esto puede requerir un tratamiento en etapas posteriores, como por ejemplo incorporar transformaciones basadas en *ColorJitter* de Pytorch dentro del pipeline de preprocesamiento. Con esta transformación podríamos generar variaciones controladas de iluminación durante el entrenamiento y así evitar que el modelo asocie incorrectamente la iluminación con la clase objetivo.



Data augmentation

En las siguientes imágenes se puede observar que existen hojas iguales, pero con una leve rotación o recorte.

