

CONCLUSIONES ENTREGA FINAL

Integrantes:

- Espínola, Carla
- Gambarte, Antonella Nerea
- Torres, Dimas Ignacio

Lineamientos derivados del EDA

Para las pruebas finales se tuvieron en cuenta las conclusiones derivadas del análisis del dataset de la primera entrega. En ese sentido se tomaron en cuenta los siguientes ítems:

- Tamaño de imágenes: existen imágenes de distintos tamaños. Es necesario adecuarlos en el preprocesamiento.
- Duplicados: existen 63 pares de imágenes duplicadas.
- Desbalance de clases: existe un claro desbalance de clases donde las clases `Orange_Huanglongbing_(citrus_greening)`, `Tomato_Tomato_Yellow_Leaf_Curl_Virus` y `Soybean_healthy` son las que se encuentran más representadas. Esto indica que se requieren estrategias de mitigación (data augmentation, pesos por clase).
- Saturación y brillo: existen algunas imágenes de la misma etiqueta que tienen más brillo que otras. Requiere transformaciones (`ColorJitter`) durante el entrenamiento.
- Distribución de colores: al analizar la distribución de colores se encontró un patrón entre las clases *healthy* y las que presentan alguna enfermedad. Las plantas que se encuentran sanas siempre presentan una barra de color verde notablemente más alta que las enfermedades lo que demuestra que la pérdida de verdor de la hoja es indicador de estrés en la planta. Además, diferentes enfermedades muestran firmas de color distintivas como clorosis (amarillo) y necrosis (marrón).

Métricas de optimización:

En agricultura, los falsos negativos son muy costosos, por lo que el recall será muy importante en el modelo seleccionado.

Los falsos positivos también son indeseados dado que si una enfermedad menos grave se detecta erróneamente, su tratamiento también es erróneo y no funcionará. Por eso también veremos la curva precision/recall y f1-score.

Modelos a utilizar

Recordemos que el fin de este trabajo es resolver un problema de clasificación, en el cuál se debe identificar una enfermedad específica en una especie de planta. En la entrega baseline, definimos que utilizaríamos modelos que puedan ser ejecutados en un dispositivo de limitados recursos, por lo que la elección de la arquitectura es clave.

En la entrega baseline, se utilizó el modelo MobileNet_V2 de PyTorch, preentrenado en ImageNet. Esta elección permitió aprovechar las representaciones visuales ya aprendidas por el modelo, reduciendo la necesidad de entrenar desde cero.

Siguiendo la misma línea, se decidió probar MobileNetV3 Small como modelo alternativo. Este modelo es más ligero que MobileNetV2, lo que lo hace especialmente adecuado para dispositivos móviles o entornos con restricciones de memoria y capacidad de cómputo.

La decisión de utilizar *Transfer Learning* se basa en que solo se entrenó la última capa del modelo, aprovechando las características generales aprendidas en ImageNet (como bordes, contornos y texturas) y adaptándolas al nuevo problema de clasificación de enfermedades de plantas. Esto permite lograr buen rendimiento sin necesidad de grandes cantidades de datos ni de entrenamiento computacional intensivo.

Pipeline de optimización

- 1) Eliminación de duplicados: se identificaron duplicados usando hashing MD5 y se eliminaron 21 imágenes detectadas.
- 2) Data augmentation selectivo: se realizó augmentation solo en clases con menos del 80% del promedio de cantidad de imágenes. Las transformaciones aplicadas fueron:
 - a) Rotación aleatoria ($\pm 20^\circ$)
 - b) Flip horizontal y vertical
 - c) Color Jitter (brillo, contraste, saturación $\pm 20\%$)
 - d) Traslación aleatoria ($\pm 10\%$)
 - e) Random Resized Crop (80-100%), recorte de la imagen haciendo zoom.
- 3) Optimización de hiperparámetros con Optuna: se implementó una estrategia de búsqueda sobre el 30% del dataset original para acelerar el tiempo de los trials, pruning automático para trials no prometedores y usamos como métrica objetivo el AUC-PR.
 - a) Los parámetros optimizados fueron:
 - i) Learning rate
 - ii) Batch size
 - iii) Arquitectura del clasificador (número de capas, neuronas, dropout)
 - iv) Tipo de optimizador (SGD vs Adam)
 - v) Weight decay (regularización)
 - b) En la arquitectura del clasificador se evaluó si agregar más capas a la clasificación ayuda o no a mejorar las métricas.

Selección del conjunto de datos a utilizar

Durante el análisis del dataset, se identificó que las imágenes estaban disponibles en tres formatos distintos: a color, segmentadas (sin fondo) y en escala de grises.

Como se mencionó al inicio, en el EDA se destacó que la coloración de las hojas es un factor clave para diferenciar plantas sanas de enfermas y para identificar el tipo de enfermedad. Por esta razón, los conjuntos a color y segmentado (que conserva el color) parecían los más adecuados para nuestro análisis.

Para decidir con cuál conjunto trabajar finalmente, se realizaron unas pruebas piloto, utilizando una submuestra de cada conjunto en modo test, con el objetivo de evaluar qué

formato ofrecía mejores resultados. A continuación, se proveen los link de las notebook donde se realizaron estas pruebas:

- [Prueba de modelos con conjunto color](#)
- [Prueba de modelos con conjunto segmented](#)

Tras realizar las pruebas piloto, se observó que las imágenes a color arrojaron mejores resultados que las segmentadas, por lo que el resto de las pruebas se realizaron utilizando ese conjunto.

Primera prueba ([Link notebook](#))

En la primera prueba se evaluó el desempeño de ambos modelos aplicados al conjunto de datos preprocesado, en el que se eliminaron las imágenes duplicadas y se aplicaron técnicas de data augmentation. Esto permitió analizar cómo cada modelo respondía ante un conjunto más limpio y variado, asegurando que el aprendizaje se centre en patrones reales de las hojas.

En ambos modelos se congelaron los parámetros del feature extractor para mantener los pesos preentrenados y evitar que se modifiquen durante el entrenamiento.

La capa final de los modelos se reemplazó por una capa lineal que adapta el número de salidas a 38, correspondiente a las clases de enfermedades vegetales presentes en nuestro dataset.


Se utilizó la función de pérdida estándar para clasificación multiclase (CrossEntropyLoss). Como optimizador se eligió el SGD aplicándose únicamente a los parámetros de la nueva capa.

Se obtuvieron los siguientes resultados:

MobileNet_V2

```
train Loss: 0.0982 Acc: 0.9769 Recall: 0.9728 F1: 0.9732 AUC-PR: 0.9932  
val Loss: 0.1116 Acc: 0.9678 Recall: 0.9620 F1: 0.9619 AUC-PR: 0.9891
```


```
Entrenamiento completado en 75m 32s  
Mejor F1 validation: 0.9619
```



MobileNetV3 Small

train Loss: 0.0982 Acc: 0.9769 Recall: 0.9728 F1: 0.9732 AUC-PR: 0.9932
val Loss: 0.1116 Acc: 0.9678 Recall: 0.9620 F1: 0.9619 AUC-PR: 0.9891

Entrenamiento completado en 75m 32s
Mejor F1 validation: 0.9619



EVALUACIÓN DE MODELOS EN TEST SET

Evaluando MobileNetV2 Básico...

Evaluando MobileNetV3 Small Básico...

RESUMEN DE RESULTADOS

	Accuracy	Recall	F1 Score	AUC-PR	Size (MB)	Inference Time (s)
MobileNetV2 Básico	0.968691	0.962033	0.962995	0.989194	9.332363	396.590889
MobileNetV3 Small Básico	0.966635	0.960590	0.960285	0.987631	6.359155	61.447430

En comparación con la entrega baseline, se registró un aumento en recall y F1-score, reflejando un mejor desempeño de los modelos en la identificación de las clases. Entre ambos, MobileNetV2 fue el que obtuvo los mejores resultados, especialmente en aquellas clases que nos propusimos mejorar respecto a la entrega baseline, que anteriormente se identificaban con menor precisión.

El uso de data augmentation selectivo aportó varios beneficios importantes. En primer lugar, permitió aumentar la cantidad de imágenes en las clases menos representadas, ayudando a balancear el dataset y reduciendo el sesgo hacia las clases más frecuentes. Además, al incluir transformaciones que modifican brillo, contraste y saturación, el modelo se volvió más robusto frente a variaciones de iluminación y saturación que se observaban en algunas imágenes, mejorando su capacidad de generalizar.

Prueba modelos con data augmentation y optuna ([Link colab](#))

En el siguiente experimento se incorporó la búsqueda de hiperparámetros con optuna.

Parámetros encontrados:

MobileNet_V2

RESULTADOS DE LA OPTIMIZACIÓN

🏆 Mejor AUC PR: 0.9894

📦 Mejores hiperparámetros:

lr : 0.0021413341205744167
batch_size : 64
hidden_dim : 512
num_layers : 1
dropout : 0.22613400786478782
optimizer : Adam
weight_decay : 0.00024393465462152218

MobileNetV3 Small

RESULTADOS DE LA OPTIMIZACIÓN

🏆 Mejor AUC PR: 0.9864

📦 Mejores hiperparámetros:

lr : 0.059329444680960054
batch_size : 32
hidden_dim : 512
num_layers : 1
dropout : 0.4225091797371915
optimizer : SGD
weight_decay : 0.0001771479661600252

Resultados:

MobileNet_V2


train Loss: 0.0722 Acc: 0.9764 Recall: 0.9724 F1: 0.9724 AUC-PR: 0.9937

val Loss: 0.1004 Acc: 0.9696 Recall: 0.9639 F1: 0.9641 AUC-PR: 0.9913

Early stopping en epoch 19

Entrenamiento completado en 50m 22s

Mejor AUC PR validation: 0.9916



MobileNetV3 Small


train Loss: 0.1384 Acc: 0.9581 Recall: 0.9513 F1: 0.9516 AUC-PR: 0.9824

val Loss: 0.1315 Acc: 0.9581 Recall: 0.9523 F1: 0.9507 AUC-PR: 0.9868

Early stopping en epoch 14

Entrenamiento completado en 38m 2s

Mejor AUC PR validation: 0.9880



La implementación de optuna logró mejorar los resultados obtenidos en la primera prueba:

- AUC-PR mejoró de 0.9892 a 0.9901 (+0.09%) para MobileNetV2.
- La optimización encontró que Adam es preferible a SGD para V2.
- El dropout óptimo es ~ 0.23 , menor que las configuraciones fijadas.
- Una sola capa en el clasificador es suficiente.

Pruebas con saturación, brillo, color como features ([Link 1](#), [Link 2](#))

En las nuevas pruebas se exploró si agregar información adicional sobre las imágenes, específicamente color, saturación y brillo, podía mejorar el desempeño del modelo. Se incorporaron estas features, permitiendo que el modelo tuviera información explícita sobre los tonos predominantes y un conocimiento más completo de las variaciones de iluminación y tonalidad presentes en el dataset.

En primer lugar, se realizaron pruebas considerando únicamente la distribución de color ([Link 1](#)) y en segundo lugar, se agregaron las características de saturación y brillo.

La incorporación de estas características adicionales buscó mejorar la capacidad del modelo de identificar patrones asociados a las diferentes enfermedades, complementando los beneficios obtenidos con el data augmentation.

Además, en estas features adicionales se incorporó Optuna para la búsqueda automática de hiperparámetros, con el objetivo de encontrar la configuración que maximice el desempeño de los modelos (Parámetros encontrados: [features color, brillo, saturación](#) , [feature color](#)).


Se obtuvieron los siguientes resultados:

Feature color:

MobileNet_V2

train Loss: 0.0824 Acc: 0.9759 Recall: 0.9715 F1: 0.9716 AUC-PR: 0.9930
val Loss: 0.1949 Acc: 0.9597 Recall: 0.9511 F1: 0.9499 AUC-PR: 0.9909
Early stopping en epoch 16


Entrenamiento completado en 17m 11s
Mejor F1 validation: 0.9666



MobileNetV3 Small

train Loss: 0.1348 Acc: 0.9574 Recall: 0.9495 F1: 0.9496 AUC-PR: 0.9839
val Loss: 0.1594 Acc: 0.9511 Recall: 0.9426 F1: 0.9419 AUC-PR: 0.9893
Early stopping en epoch 12

Entrenamiento completado en 13m 8s
Mejor F1 validation: 0.9483



Con la incorporación de la distribución del color hubieron algunas modificaciones:


- AUC-PR mejoró significativamente de 0.9901 a 0.9917 (+0.16%).
- El Recall mejoró de 0.9598 a 0.9610 (+0.12%).
- El tamaño del modelo aumentó debido a las features adicionales.
- La información de color aporta valor discriminativo para enfermedades con cambios de coloración.

Feature color, saturación y brillo:

MobileNet_V2

train Loss: 0.0943 Acc: 0.9710 Recall: 0.9660 F1: 0.9661 AUC-PR: 0.9915
 val Loss: 0.1462 Acc: 0.9575 Recall: 0.9516 F1: 0.9502 AUC-PR: 0.9908
 Early stopping en epoch 16


Entrenamiento completado en 20m 17s
 Mejor F1 validation: 0.9638



MobileNetV3 Small

train Loss: 0.1321 Acc: 0.9600 Recall: 0.9531 F1: 0.9532 AUC-PR: 0.9854
 val Loss: 0.1807 Acc: 0.9494 Recall: 0.9401 F1: 0.9392 AUC-PR: 0.9895
 Early stopping en epoch 20

Entrenamiento completado en 24m 57s
 Mejor F1 validation: 0.9532





Claramente la incorporación del color, saturación y brillo como features ayudaron a mejorar el desempeño de ambos modelos.


- AUC-PR alcanzó 0.9922, el mejor de toda la serie de experimentos.
- F1 Score mejoró de 0.9629 a 0.9640 (+0.11%).
- Recall ligeramente mejor en 0.9614.

Gráficos de resultados

Los resultados de las métricas de desempeño entre el modelo MobileNetV2 y el MobileNetV3 small favorecen en todos los casos al modelo v2.



La diferencia más significativa se ve en la reducción de tamaño del modelo v3, varias veces menor que el V2 y principalmente en el tiempo de inferencia. Considerando esta reducción del tiempo de inferencia se pone en juego el número de inferencias que podrían hacerse en el mismo tiempo, tomando seis fotos de diferentes hojas estas podrían ser clasificadas por el modelo V3 small en el mismo tiempo que le lleva clasificar una sola imagen al modelo V2.




Dependiendo de la velocidad de muestreo se va a favorecer a uno u otro modelo, en caso de querer tomar solo una foto de plantas que están a una distancia considerable se debería usar el modelo V2 y en cambio si el intervalo entre muestra es de solo un minuto la balanza se inclinaría a favor del modelo V3.

Resultados del data Augmentation


Agregar la distribución de colores en los pixeles aporta información valiosa de cada clase. Se obtuvieron mejoras cuando se aplicaron como features en el modelo.

A continuación se observan los gráficos comparativos para el experimento con 03 con features de color.



Los siguiente gráficos refieren al experimento 04 donde se agregan la saturación y el brillo como features.

Se pueden ver los resultados mejorados con esta modificación.



Cada experimento aportó mejoras medibles:

- Data Augmentation: Estableció una base sólida.
- Optuna: +0.09% AUC-PR.
- Features de Color: +0.25% AUC-PR.
- Features Sat/Brillo: +0.30% AUC-PR total.

Se identificó una confusión entre enfermedades similares del maíz (Northern Leaf Blight vs Gray Leaf Spot).

Por esto, para el manejo de clases difíciles se podría:

- Solicitar otra imagen dependiendo de la confianza de la clasificación.
- Para enfermedades similares podemos presentar Top-2 de predicciones al usuario.

El umbral de confianza para recomendaciones generales puede estar definido alrededor de 0.85, mientras que para detección crítica (Late Blight, HLB) se podría bajar para tener mayor captura teniendo cuidado con los falsos positivos.