

CONCLUSIONES ENTREGA FINAL

Integrantes:

- Espínola, Carla
- Gambarte, Antonella Nerea
- Torres, Dimas Ignacio

Lineamientos derivados del EDA

Para las pruebas finales se tuvieron en cuenta las conclusiones derivadas del análisis del dataset de la primera entrega. En ese sentido se tomaron en cuenta los siguientes ítems:

- Tamaño de imágenes: existen imágenes de distintos tamaños. Es necesario adecuarlos en el preprocesamiento.
- Duplicados: existen 63 pares de imágenes duplicadas.
- Desbalance de clases: existe un claro desbalance de clases donde las clases Orange_Huanglongbing_(citrus_greening) , Tomato_Tomato_Yellow_Leaf_Curl_Virus y Soybean_healthy son las que se encuentran más representadas. Esto indica que se requieren estrategias de mitigación (data augmentation, pesos por clase).
- Saturación y brillo: existen algunas imágenes de la misma etiqueta que tienen más brillo que otras. Requiere transformaciones (ColorJitter) durante el entrenamiento.
- Distribución de colores: al analizar la distribución de colores se encontró un patrón entre las clases *healthy* y las que presentan alguna enfermedad. Las plantas que se encuentran sanas siempre presentan una barra de color verde notablemente más alta que las enfermedades lo que demuestra que la pérdida de verdor de la hoja es indicador de estrés en la planta. Además, diferentes enfermedades muestran firmas de color distintivas como clorosis (amarillo) y necrosis (marrón).

Métricas de optimización:

En agricultura, los falsos negativos son muy costosos, por lo que el recall será muy importante en el modelo seleccionado.

Los falsos positivos también son indeseados dado que si una enfermedad menos grave se detecta erróneamente, su tratamiento también es erróneo y no funcionará. Por eso también veremos la curva precision/recall y f1-score.

Modelos a utilizar

Recordemos que el fin de este trabajo es resolver un problema de clasificación, en el cuál se debe identificar una enfermedad específica en una especie de planta. En la entrega baseline, definimos que utilizaríamos modelos que puedan ser ejecutados en un dispositivo de limitados recursos, por lo que la elección de la arquitectura es clave.

En la entrega baseline, se utilizó el modelo MobileNet_V2 de PyTorch, preentrenado en ImageNet. Esta elección permitió aprovechar las representaciones visuales ya aprendidas por el modelo, reduciendo la necesidad de entrenar desde cero. Siguiendo la misma línea, se decidió probar MobileNetV3 Small como modelo alternativo. Este modelo es más ligero que MobileNetV2, lo que lo hace especialmente adecuado para dispositivos móviles o entornos con restricciones de memoria y capacidad de cómputo. La decisión de utilizar *Transfer Learning* se basa en que solo se entrenó la última capa del modelo, aprovechando las características generales aprendidas en ImageNet (como bordes, contornos y texturas) y adaptándolas al nuevo problema de clasificación de enfermedades de plantas. Esto permite lograr buen rendimiento sin necesidad de grandes cantidades de datos ni de entrenamiento computacional intensivo.

Pipeline de optimización

- 1) Eliminación de duplicados: se identificaron duplicados usando hashing MD5 y se eliminaron 21 imágenes detectadas.
- 2) Data augmentation selectivo: se realizó augmentation solo en clases con menos del 80% del promedio de cantidad de imágenes. Las transformaciones aplicadas fueron:
 - a) Rotación aleatoria ($\pm 20^\circ$)
 - b) Flip horizontal y vertical
 - c) Color Jitter (brillo, contraste, saturación $\pm 20\%$)
 - d) Traslación aleatoria ($\pm 10\%$)
 - e) Random Resized Crop (80-100%), recorte de la imagen haciendo zoom.
- 3) Optimización de hiperparámetros con Optuna: se implementó una estrategia de búsqueda sobre el 30% del dataset original para acelerar el tiempo de los trials, pruning automático para trials no prometedores y usamos como métrica objetivo el AUC-PR.
 - a) Los parámetros optimizados fueron:
 - i) Learning rate
 - ii) Batch size
 - iii) Arquitectura del clasificador (número de capas, neuronas, dropout)
 - iv) Tipo de optimizador (SGD vs Adam)
 - v) Weight decay (regularización)
 - b) En la arquitectura del clasificador se evaluó si agregar más capas a la clasificación ayuda o no a mejorar las métricas.

Selección del conjunto de datos a utilizar

Durante el análisis del dataset, se identificó que las imágenes estaban disponibles en tres formatos distintos: a color, segmentadas (sin fondo) y en escala de grises. Como se mencionó al inicio, en el EDA se destacó que la coloración de las hojas es un factor clave para diferenciar plantas sanas de enfermas y para identificar el tipo de enfermedad. Por esta razón, los conjuntos a color y segmentado (que conserva el color) parecían los más adecuados para nuestro análisis. Para decidir con cuál conjunto trabajar finalmente, se realizaron unas pruebas piloto, utilizando una submuestra de cada conjunto en modo test, con el objetivo de evaluar qué


formato ofrecía mejores resultados. A continuación, se proveen los link de las notebook donde se realizaron estas pruebas:

- [Prueba de modelos con conjunto color](#)
- [Prueba de modelos con conjunto segmented](#)


Tras realizar las pruebas piloto, se observó que las imágenes a color arrojaron mejores resultados que las segmentadas, por lo que el resto de las pruebas se realizaron utilizando ese conjunto

Gráficos de resultados

Los resultados de las métricas de desempeño entre el modelo MobileNetV2 y el MobileNetV3 small favorecen en todos los casos al modelo v2.



La diferencia más significativa se ve en la reducción de tamaño del modelo v3, varias veces menor que el V2 y principalmente en el tiempo de inferencia. Considerando esta reducción del tiempo de inferencia se pone en juego el número de inferencias que podrían hacerse en el mismo tiempo, tomando seis fotos de diferentes hojas estas podrían ser clasificadas por el modelo V3 small en el mismo tiempo que le lleva clasificar una sola imagen al modelo V2.




Dependiendo de la velocidad de muestreo se va a favorecer a uno u otro modelo, en caso de querer tomar solo una foto de plantas que están a una distancia considerable se debería usar el modelo V2 y en cambio si el intervalo entre muestra es de solo un minuto la balanza se inclinaría a favor del modelo V3.


Resultados del data Augmentation

Pese a que el EDA había indicado claramente que la distribución de colores en los pixeles aporta información valiosa de cada clase no se obtuvieron mejoras cuando se aplicaron como features en el modelo.

Los siguiente gráficos refieren a la implementación de la saturación y el brillo como features. Se pueden ver los resultados sub-óptimos con esta modificación.



Como se puede ver en los gráficos siguientes la inclusión de la distribución de colores tuvo un efecto deletéreo aún más marcado.



Este resultado se puede racionalizar teniendo en cuenta que la información sobre la distribución de colores puede ser aprendida directamente por modelo directamente desde la imágenes. Habiendo introducido estos nuevos features sin una forma racional de embedding puede haber resultado contraproducente para ambos modelos, aunque se puede ver claramente que el efecto sobre el modelo MobileNetV3 small fue mucho menor por lo que se puede concluir que este modelo es más robusto frente a features interferentes.