

CONCLUSIONES ENTREGA FINAL

Integrantes:

- Espínola, Carla
- Gambarte, Antonella Nerea
- Torres, Dimas Ignacio

Lineamientos derivados del EDA

Para las pruebas finales se tuvieron en cuenta las conclusiones derivadas del análisis del dataset de la primera entrega. En ese sentido se tomaron en cuenta los siguientes ítems:

- Tamaño de imágenes: existen imágenes de distintos tamaños. Es necesario adecuarlos en el preprocesamiento.
- Duplicados: existen 63 pares de imágenes duplicadas.
- Desbalance de clases: existe un claro desbalance de clases donde las clases `Orange_Huanglongbing_(citrus_greening)`, `Tomato_Tomato_Yellow_Leaf_Curl_Virus` y `Soybean_healthy` son las que se encuentran más representadas. Esto indica que se requieren estrategias de mitigación (data augmentation, pesos por clase).
- Saturación y brillo: existen algunas imágenes de la misma etiqueta que tienen más brillo que otras. Requiere transformaciones (`ColorJitter`) durante el entrenamiento.
- Distribución de colores: al analizar la distribución de colores se encontró un patrón entre las clases *healthy* y las que presentan alguna enfermedad. Las plantas que se encuentran sanas siempre presentan una barra de color verde notablemente más alta que las enfermedades lo que demuestra que la pérdida de verdor de la hoja es indicador de estrés en la planta. Además, diferentes enfermedades muestran firmas de color distintivas como clorosis (amarillo) y necrosis (marrón).

Métricas de optimización:

En agricultura, los falsos negativos son muy costosos, por lo que el recall será muy importante en el modelo seleccionado.

Los falsos positivos también son indeseados dado que si una enfermedad menos grave se detecta erróneamente, su tratamiento también es erróneo y no funcionará. Por eso también veremos la curva precision/recall y f1-score.

Modelos a utilizar

Recordemos que el fin de este trabajo es resolver un problema de clasificación, en el cuál se debe identificar una enfermedad específica en una especie de planta. En la entrega baseline, definimos que utilizaríamos modelos que puedan ser ejecutados en un dispositivo de limitados recursos, por lo que la elección de la arquitectura es clave.

En la entrega baseline, se utilizó el modelo MobileNet_V2 de PyTorch, preentrenado en ImageNet. Esta elección permitió aprovechar las representaciones visuales ya aprendidas por el modelo, reduciendo la necesidad de entrenar desde cero.

Siguiendo la misma línea, se decidió probar MobileNetV3 Small como modelo alternativo. Este modelo es más ligero que MobileNetV2, lo que lo hace especialmente adecuado para dispositivos móviles o entornos con restricciones de memoria y capacidad de cómputo.

La decisión de utilizar *Transfer Learning* se basa en que solo se entrenó la última capa del modelo, aprovechando las características generales aprendidas en ImageNet (como bordes, contornos y texturas) y adaptándolas al nuevo problema de clasificación de enfermedades de plantas. Esto permite lograr buen rendimiento sin necesidad de grandes cantidades de datos ni de entrenamiento computacional intensivo.

Pipeline de optimización

- 1) Eliminación de duplicados: se identificaron duplicados usando hashing MD5 y se eliminaron 21 imágenes detectadas.
- 2) Data augmentation selectivo: se realizó augmentation solo en clases con menos del 80% del promedio de cantidad de imágenes. Las transformaciones aplicadas fueron:
 - a) Rotación aleatoria ($\pm 20^\circ$)
 - b) Flip horizontal y vertical
 - c) Color Jitter (brillo, contraste, saturación $\pm 20\%$)
 - d) Traslación aleatoria ($\pm 10\%$)
 - e) Random Resized Crop (80-100%), recorte de la imagen haciendo zoom.
- 3) Optimización de hiperparámetros con Optuna: se implementó una estrategia de búsqueda sobre el 30% del dataset original para acelerar el tiempo de los trials, pruning automático para trials no prometedores y usamos como métrica objetivo el AUC-PR.
 - a) Los parámetros optimizados fueron:
 - i) Learning rate
 - ii) Batch size
 - iii) Arquitectura del clasificador (número de capas, neuronas, dropout)
 - iv) Tipo de optimizador (SGD vs Adam)
 - v) Weight decay (regularización)
 - b) En la arquitectura del clasificador se evaluó si agregar más capas a la clasificación ayuda o no a mejorar las métricas.

Selección del conjunto de datos a utilizar

Durante el análisis del dataset, se identificó que las imágenes estaban disponibles en tres formatos distintos: a color, segmentadas (sin fondo) y en escala de grises.

Como se mencionó al inicio, en el EDA se destacó que la coloración de las hojas es un factor clave para diferenciar plantas sanas de enfermas y para identificar el tipo de enfermedad. Por esta razón, los conjuntos a color y segmentado (que conserva el color) parecían los más adecuados para nuestro análisis.

Para decidir con cuál conjunto trabajar finalmente, se realizaron unas pruebas piloto, utilizando una submuestra de cada conjunto en modo test, con el objetivo de evaluar qué

formato ofrecía mejores resultados. A continuación, se proveen los link de las notebook donde se realizaron estas pruebas:

- [Prueba de modelos con conjunto color](#)
- [Prueba de modelos con conjunto segmented](#)

Tras realizar las pruebas piloto, se observó que las imágenes a color arrojaron mejores resultados que las segmentadas, por lo que el resto de las pruebas se realizaron utilizando ese conjunto.

Primera prueba ([Link notebook](#))

En la primera prueba se evaluó el desempeño de ambos modelos aplicados al conjunto de datos preprocesado, en el que se eliminaron las imágenes duplicadas y se aplicaron técnicas de data augmentation. Esto permitió analizar cómo cada modelo respondía ante un conjunto más limpio y variado, asegurando que el aprendizaje se centrara en patrones reales de las hojas.

En ambos modelos se congelaron los parámetros del feature extractor para mantener los pesos preentrenados y evitar que se modifiquen durante el entrenamiento.

La capa final de los modelos se reemplazó por una capa lineal que adapta el número de salidas a 38, correspondiente a las clases de enfermedades vegetales presentes en nuestro dataset.


Se utilizó la función de pérdida estándar para clasificación multiclase (CrossEntropyLoss). Como optimizador se eligió el SGD aplicándose únicamente a los parámetros de la nueva capa.

Se obtuvieron los siguientes resultados:

MobileNet_V2

```
train Loss: 0.0857 Acc: 0.9796 Recall: 0.9757 F1: 0.9761 AUC-PR: 0.9943
val Loss: 0.1002 Acc: 0.9690 Recall: 0.9639 F1: 0.9635 AUC-PR: 0.9911
Early stopping en epoch 41


Entrenamiento completado en 101m 38s
Mejor F1 validation: 0.9653
```



MobileNetV3 Small

```
train Loss: 0.0916 Acc: 0.9722 Recall: 0.9672 F1: 0.9674 AUC-PR: 0.9913  
val Loss: 0.1025 Acc: 0.9682 Recall: 0.9606 F1: 0.9610 AUC-PR: 0.9893  
Early stopping en epoch 48
```

```
Entrenamiento completado en 108m 45s  
Mejor F1 validation: 0.9616
```



EVALUACIÓN DE MODELOS EN TEST SET						
Evaluando MobileNetV2 Básico...						
Evaluando MobileNetV3 Small Básico...						
RESUMEN DE RESULTADOS						
	Accuracy	Recall	F1 Score	AUC-PR	Size (MB)	Inference Time (s)
MobileNetV2 Básico	0.974858	0.970650	0.970507	0.992058	9.332363	384.351237
MobileNetV3 Small Básico	0.966319	0.959155	0.959720	0.989754	6.359155	64.524365

En comparación con la entrega baseline, se registró un aumento en recall y F1-score, reflejando un mejor desempeño de los modelos en la identificación de las clases. Entre ambos, MobileNetV2 fue el que obtuvo los mejores resultados, especialmente en aquellas clases que nos propusimos mejorar respecto a la entrega baseline, que anteriormente se identificaban con menor precisión.

El uso de data augmentation selectivo aportó varios beneficios importantes. En primer lugar, permitió aumentar la cantidad de imágenes en las clases menos representadas, ayudando a balancear el dataset y reduciendo el sesgo hacia las clases más frecuentes. Además, al incluir transformaciones que modifican brillo, contraste y saturación, el modelo se volvió más robusto frente a variaciones de iluminación y saturación que se observaban en algunas imágenes, mejorando su capacidad de generalizar.

Pruebas con saturación, brillo, color como features ([Link 1](#), [Link 2](#))

En las nuevas pruebas se exploró si agregar información adicional sobre las imágenes, específicamente color, saturación y brillo, podía mejorar el desempeño del modelo. Se incorporaron estas features ([Link 2](#)), permitiendo que el modelo tuviera información explícita sobre los tonos predominantes y un conocimiento más completo de las variaciones de iluminación y tonalidad presentes en el dataset.

Posteriormente, se realizaron pruebas considerando únicamente la distribución de color ([Link 1](#)), con el objetivo de evaluar el efecto de usar solo esta característica frente a la combinación más completa de color, saturación y brillo.

La incorporación de estas características adicionales buscó mejorar la capacidad del modelo de identificar patrones asociados a las diferentes enfermedades, complementando los beneficios obtenidos con el data augmentation.

Además, en estas features adicionales se incorporó Optuna para la búsqueda automática de hiperparámetros, con el objetivo de encontrar la configuración que maximice el desempeño de los modelos (Parámetros encontrados: [features color, brillo, saturación](#) , [feature color](#)).


Se obtuvieron los siguientes resultados:

Feature color, saturación y brillo:

MobileNet_V2

```
train Loss: 2.6751 Acc: 0.2507 Recall: 0.1636 F1: 0.1501 AUC-PR: 0.1496  
val Loss: 2.5221 Acc: 0.2633 Recall: 0.1550 F1: 0.1345 AUC-PR: 0.1964  
Early stopping en epoch 8
```


```
Entrenamiento completado en 45m 47s  
Mejor F1 validation: 0.1730
```



MobileNetV3 Small

```
train Loss: 0.1583 Acc: 0.9483 Recall: 0.9399 F1: 0.9399 AUC-PR: 0.9793  
val Loss: 0.1648 Acc: 0.9451 Recall: 0.9385 F1: 0.9361 AUC-PR: 0.9860  
Early stopping en epoch 12
```

```
Entrenamiento completado en 65m 57s  
Mejor F1 validation: 0.9449
```




Feature color:

MobileNet_V2

```
train Loss: 1.3054 Acc: 0.5962 Recall: 0.5414 F1: 0.5403 AUC-PR: 0.5786
val Loss: 1.0594 Acc: 0.6883 Recall: 0.6323 F1: 0.6201 AUC-PR: 0.7812
Early stopping en epoch 14


Entrenamiento completado en 69m 29s
Mejor F1 validation: 0.8300
```



MobileNetV3 Small

```
train Loss: 1.1855 Acc: 0.9272 Recall: 0.9170 F1: 0.9170 AUC-PR: 0.9488  
val Loss: 0.9200 Acc: 0.9374 Recall: 0.9286 F1: 0.9295 AUC-PR: 0.9723  
Early stopping en epoch 9
```

```
Entrenamiento completado en 42m 28s  
Mejor F1 validation: 0.9322
```



Claramente la incorporación del color, saturación y brillo como features perjudicaron completamente el desempeño de ambos modelos.

Prueba modelos con data augmentation y optuna [\(Link colab\)](#)

Otra prueba realizada fue tomando como base lo de la primera prueba, que dio buenos resultados, e incorporando la búsqueda de hiperparámetros con optuna.

Parámetros encontrados:

MobileNet_V2

RESULTADOS DE LA OPTIMIZACIÓN

🏆 Mejor AUC PR: 0.9856

📄 Mejores hiperparámetros:

```
lr      : 0.0023345864076016252  
batch_size : 32  
hidden_dim : 1024  
num_layers : 1  
dropout   : 0.12602063719411183  
optimizer : Adam  
weight_decay : 0.0002661901888489054
```

MobileNetV3 Small

RESULTADOS DE LA OPTIMIZACIÓN

🏆 Mejor AUC PR: 0.9712

📋 Mejores hiperparámetros:

lr : 0.0023345864076016252
batch_size : 32
hidden_dim : 1024
num_layers : 1
dropout : 0.12602063719411183
optimizer : Adam
weight_decay : 0.0002661901888489054


Resultados:

MobileNet_V2

train Loss: 0.1307 Acc: 0.9574 Recall: 0.9501 F1: 0.9501 AUC-PR: 0.9848
val Loss: 0.1264 Acc: 0.9623 Recall: 0.9584 F1: 0.9562 AUC-PR: 0.9906
Early stopping en epoch 10

Entrenamiento completado en 12m 21s

Mejor AUC PR validation: 0.9910




MobileNetV3 Small

train Loss: 0.1481 Acc: 0.9582 Recall: 0.9507 F1: 0.9511 AUC-PR: 0.9836
val Loss: 0.1567 Acc: 0.9502 Recall: 0.9369 F1: 0.9382 AUC-PR: 0.9864
Early stopping en epoch 14

Entrenamiento completado en 17m 19s


Mejor AUC PR validation: 0.9868





La implementación de optuna no logró mejorar los resultados obtenidos en la primera prueba.



Gráficos de resultados

Los resultados de las métricas de desempeño entre el modelo MobileNetV2 y el MobileNetV3 small favorecen en todos los casos al modelo v2.





La diferencia más significativa se ve en la reducción de tamaño del modelo v3, varias veces menor que el V2 y principalmente en el tiempo de inferencia. Considerando esta reducción del tiempo de inferencia se pone en juego el número de inferencias que podrían hacerse en el mismo tiempo, tomando seis fotos de diferentes hojas estas podrían ser clasificadas por el modelo V3 small en el mismo tiempo que le lleva clasificar una sola imagen al modelo V2.




Dependiendo de la velocidad de muestreo se va a favorecer a uno u otro modelo, en caso de querer tomar solo una foto de plantas que están a una distancia considerable se debería usar el modelo V2 y en cambio si el intervalo entre muestra es de solo un minuto la balanza se inclinaría a favor del modelo V3.

Resultados del data Augmentation


Pese a que el EDA había indicado claramente que la distribución de colores en los pixeles aporta información valiosa de cada clase no se obtuvieron mejoras cuando se aplicaron como features en el modelo.

Los siguiente gráficos refieren a la implementación de la saturación y el brillo como features.

Se pueden ver los resultados sub-óptimos con esta modificación.



Como se puede ver en los gráficos siguientes la inclusión de la distribución de colores tuvo un efecto deletéreo aún más marcado.



Este resultado se puede racionalizar teniendo en cuenta que la información sobre la distribución de colores puede ser aprendida por modelo directamente desde las imágenes. Habiendo introducido estos nuevos features sin una forma racional de embedding puede haber resultado contraproducente para ambos modelos, aunque se puede ver claramente

que el efecto sobre el modelo MobileNetV3 small fue mucho menor por lo que se puede concluir que este modelo es más robusto frente a features interferentes.